

# Interest Point Detection

# Object Detection / Image registration

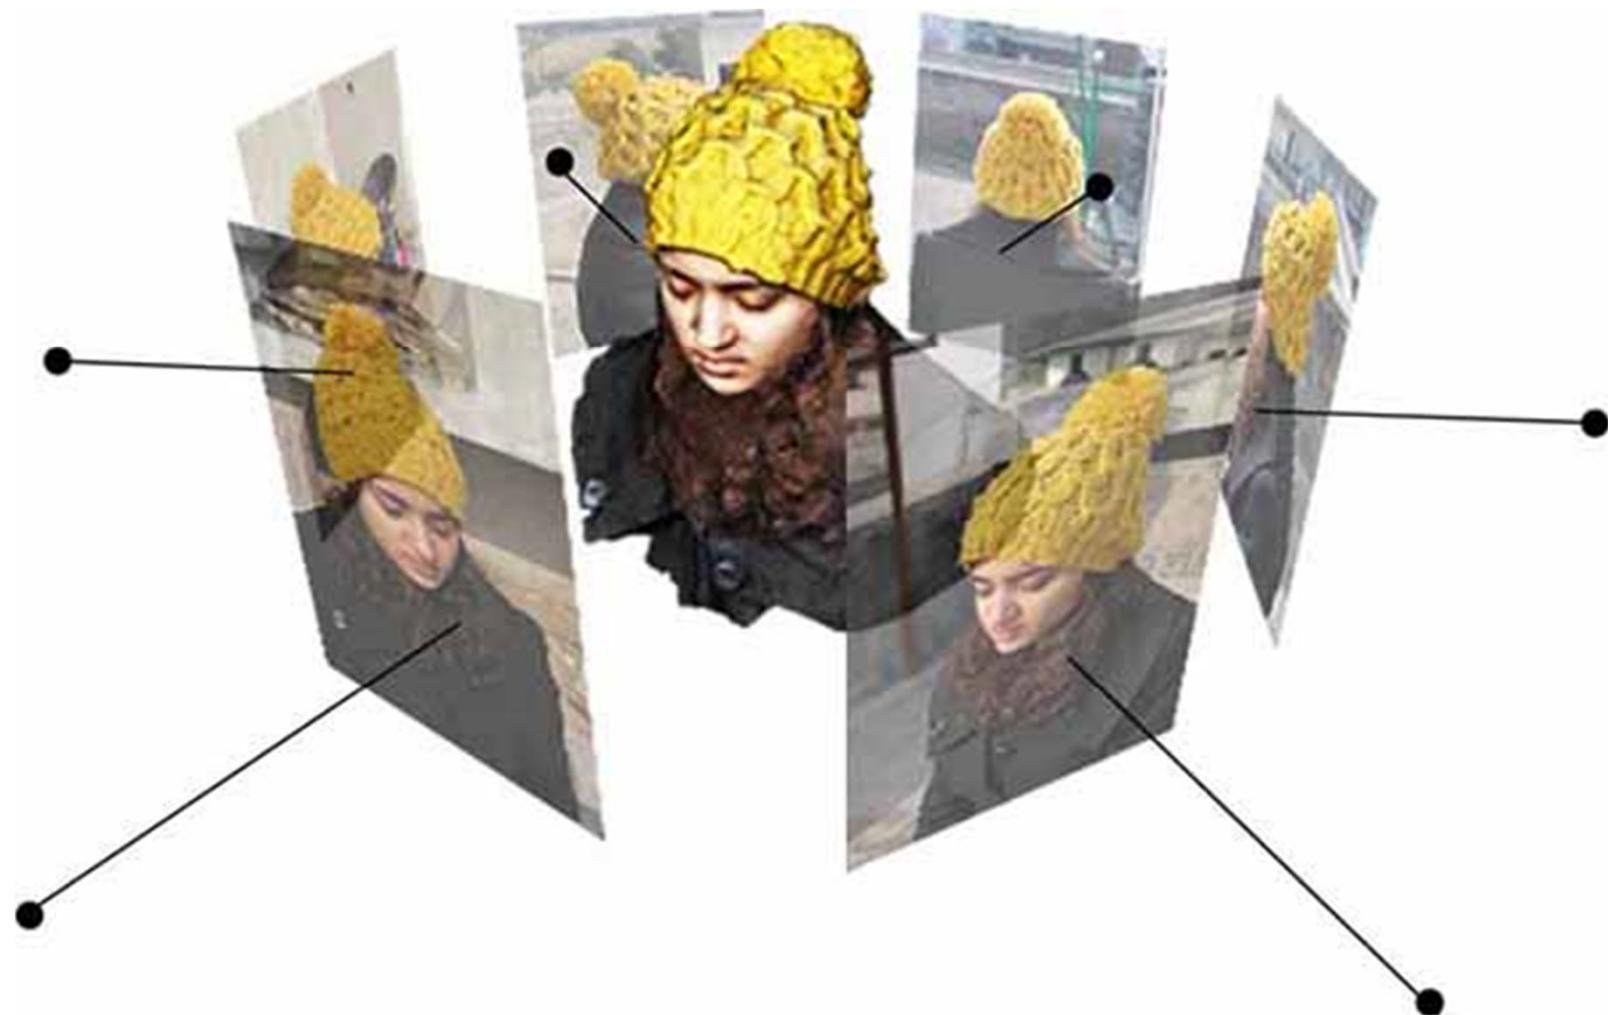


- SIFT

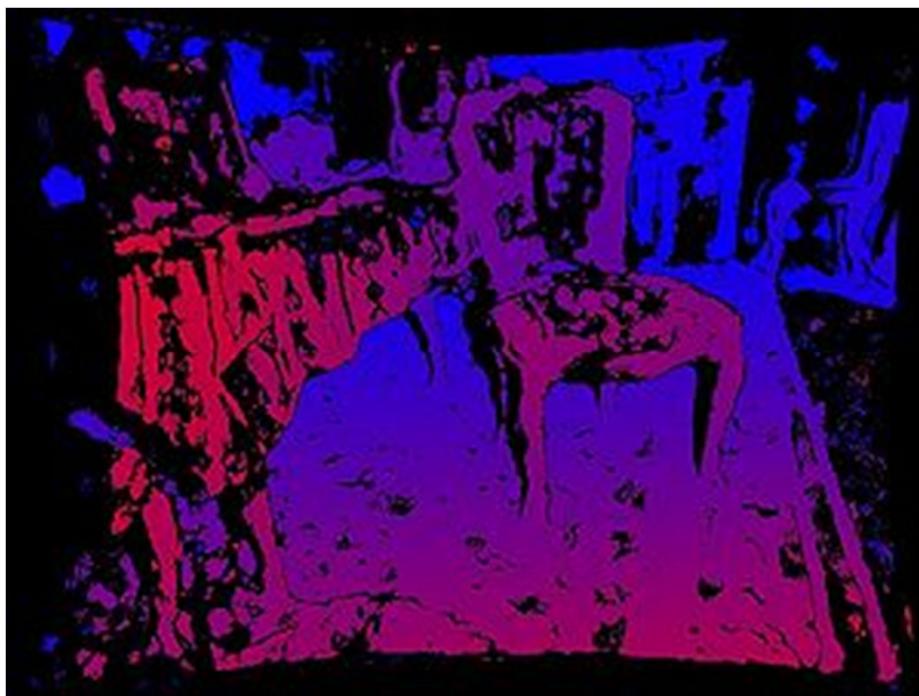
# Stitching



# 3D-Rekonstruktion



# Stereo Vision



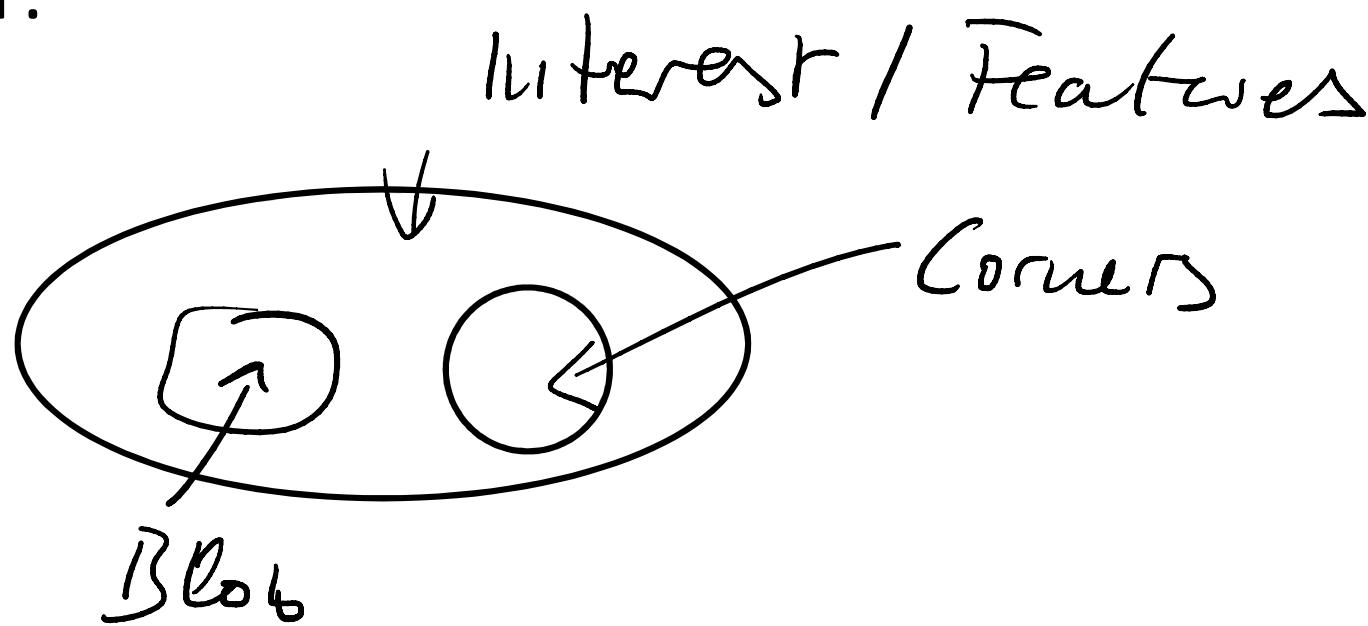
# Optical Flow

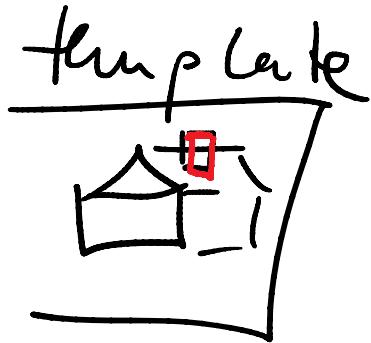
# Definition Interest Points

- wohl definierte, mathematische Beschreibung
- lokalisiert
- robust unter verschiedenen  
Abbildungsbedingungen („repeatable“)
- historisch: „Corner Points“

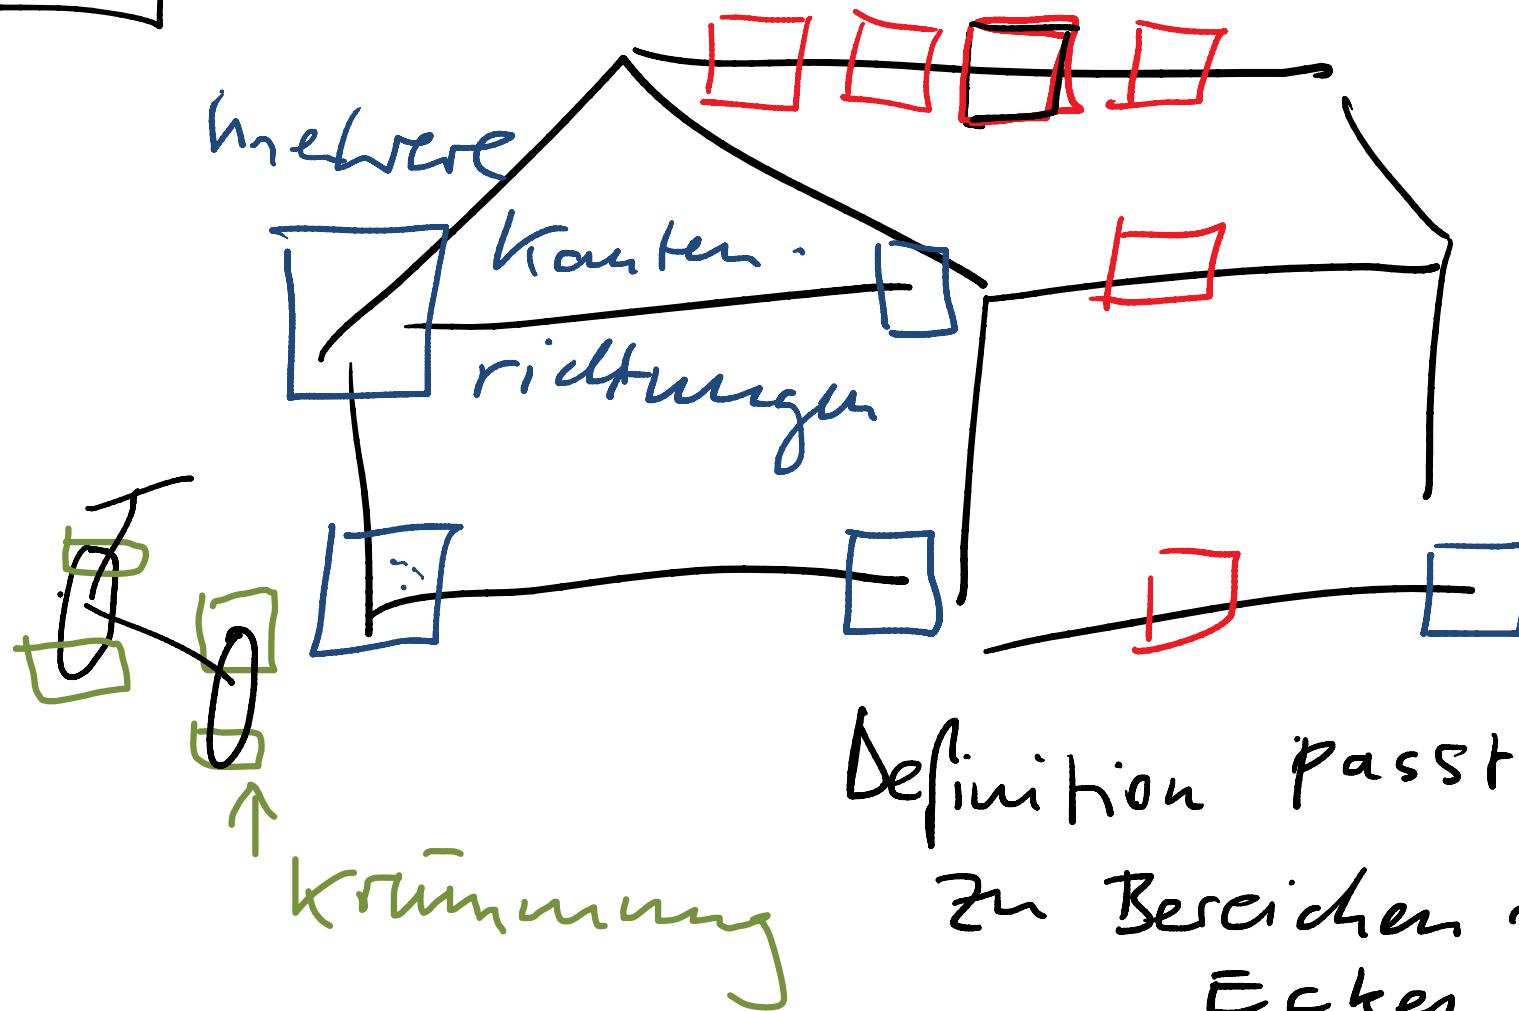
# Vokabular

- In vielen papers:  
Corners = Interest Points = Feature Points
- Hier:





Kanten sind nicht  
einheitig



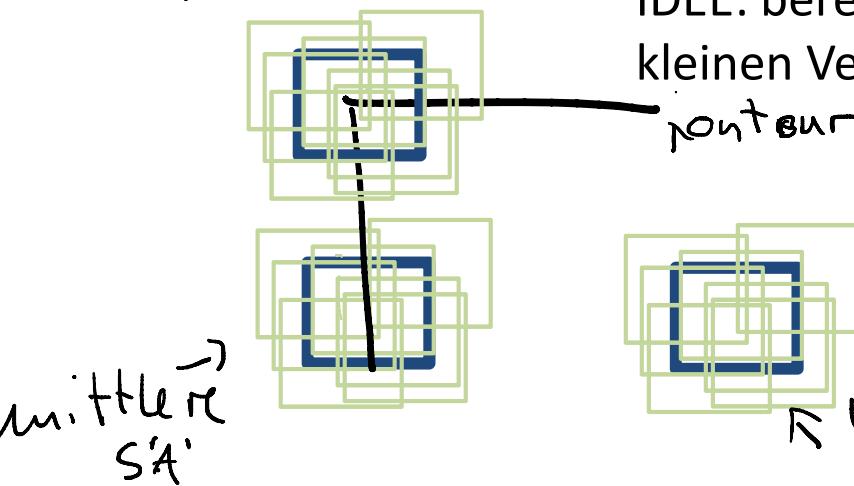
Definition passt auch  
zu Bereichen ohne  
Ecken..

# Moravec's Corners

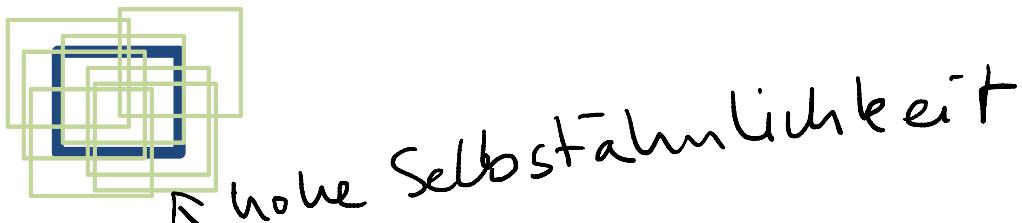
- „Corner“ defined as window with low self-similarity (large sum of squared differences)

$$SSD = \sum_x \sum_y (w_1(x, y) - w_2(x, y))^2$$

geringe Selbstähn.



IDEE: berechne mittlere SSD über eine Liste von kleinen Verschiebungen



# Zusammenhang von SSD und Korrelation

$$\text{SSD} = \sum \left| \vec{\omega}_1 - \vec{\omega}_2 \right|^2 \text{ minimieren}$$
$$= \sum \underbrace{\vec{\omega}_1^2}_{\text{keine Beziehung zu } \vec{\omega}_2} - 2 \vec{\omega}_1 \cdot \vec{\omega}_2 + \underbrace{\vec{\omega}_2^2}_{\text{keine Beziehung zu } \vec{\omega}_1} \text{ maximieren}$$
$$\approx - \vec{\omega}_1 \otimes \vec{\omega}_2 \uparrow \text{Korrelation}$$

# Harris Corner Detection (Erweiterung von Moravec)

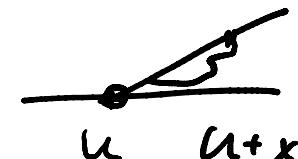
$$S(x, y) = \sum_u \sum_v w(u, v) (I(u + x, v + y) - I(u, v))^2$$

SSD

$I(u + x, v + y)$  can be approximated by a Taylor expansion. Let  $I_x$  and  $I_y$  be the partial derivatives of  $I$ , such that

$$I(u + x, v + y) \approx I(u, v) + I_x(u, v)x + I_y(u, v)y$$

This produces the approximation — erste Ansatz.



$$S(x, y) \approx \sum_u \sum_v w(u, v) (I_x(u, v)x + I_y(u, v)y)^2,$$

which can be written in matrix form:

$$S(x, y) \approx (x \ y) A \begin{pmatrix} x \\ y \end{pmatrix}, \quad \overbrace{I_x^2(u, v)}$$

where  $A$  is the structure tensor,

$$A = \sum_u \sum_v w(u, v) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} = \begin{bmatrix} \langle I_x^2 \rangle & \langle I_x I_y \rangle \\ \langle I_x I_y \rangle & \langle I_y^2 \rangle \end{bmatrix}$$



## Harris Corner Detection

$$S(x, y) = \sum_u \sum_v w(u, v) (I(u + x, v + y) - I(u, v))^2$$

*das verschobene Bild*

*das Bild*

Window, ist zwar üblich definiert,  
aber nur dort >0, wo wir den  
Test machen (eine Maske)

Die Idee von Harris war,  $S$  um  $(u, v)$  herum zu expandieren, d.h. eine Gleichung zu finden, die das originale Kewster nutzt

$I(u+x, v+y)$  can be approximated by a Taylor expansion. Let  $I_x$  and  $I_y$  be the partial derivatives of  $I$ , such that

$$\underbrace{I(u+x, v+y)}_{\text{verschobenes Bild}} \approx \underbrace{I(u, v) + I_x(u, v)x + I_y(u, v)y}_{\text{Taylor-Expansion}}$$

verschobenes  
Bild

Taylor-Expansion,  
lässt höhere

$I_x$ : Abl. des Bildes  
in x-Richt.

Teile weg!

$I_y$ : Abl. in y-  
Richt.

(Annahme: für kleine  
Verschiebungen  $(x, y)$  nach OH)

This produces the approximation

$$S(x, y) \approx \sum_u \sum_v w(u, v) \underbrace{(I_x(u, v)x + I_y(u, v)y)^2},$$

$$I_x^2 x^2 + 2 \cdot I_x I_y \cdot x \cdot y + I_y^2 y^2$$

$$(x \ y) \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

which can be written in matrix form:

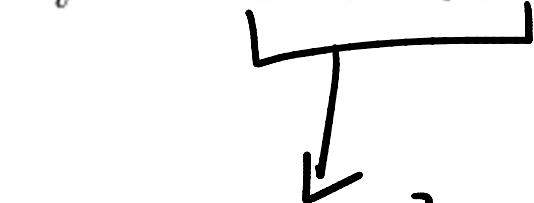
$$S(x, y) \approx (x \ y) A \begin{pmatrix} x \\ y \end{pmatrix},$$

remember:

$S$  soll maximal sein

where  $A$  is the structure tensor,

$$A = \sum_u \sum_v w(u, v) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} = \begin{bmatrix} \langle I_x^2 \rangle & \langle I_x I_y \rangle \\ \langle I_x I_y \rangle & \langle I_y^2 \rangle \end{bmatrix}$$



$$(I_x(u,v))^2$$

$$I_x(u,v) \cdot I_y(u,v)$$

$$I_x(u,v) \cdot I_y(u,v)$$

$$(I_y(u,v))^2$$

Quadrat der  
Summe aller x-Komponenten

↓ der Ableitung

$$A = \begin{bmatrix} \langle I_x^2 \rangle & \langle I_x I_y \rangle \\ \langle I_x I_y \rangle & \langle I_y^2 \rangle \end{bmatrix}$$

groß  
wenig Gradient  
 $\sim 45^\circ + k \cdot g_0^\circ$

A hat Ähnlichkeit zur Kovarianz-  
matrix! Ist Sie aber nicht!

$$S(x,y) \approx (x \ y) \begin{matrix} A \\ \boxed{A} \end{matrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

$\uparrow$   
 $\uparrow$   
 $\downarrow$

für ein gegebenes Fenster ( $w(u,v)$ )  
 Variieren wir  $x,y$  in einem kleinen  
 Bereich.  $\Rightarrow S$  ist nur abhängig von  
 $A (= A(u,v))$ !  
 Die Werte für  $x,y$  sind immer  
 die selben für verschiedene  
 Suchfenster...



$$I + [-1 \ 0 \ 1]$$



$$I_X^T$$

$$I * [-1 \ 0 \ 1]^T$$



$$I_J^T$$

Suchfenster

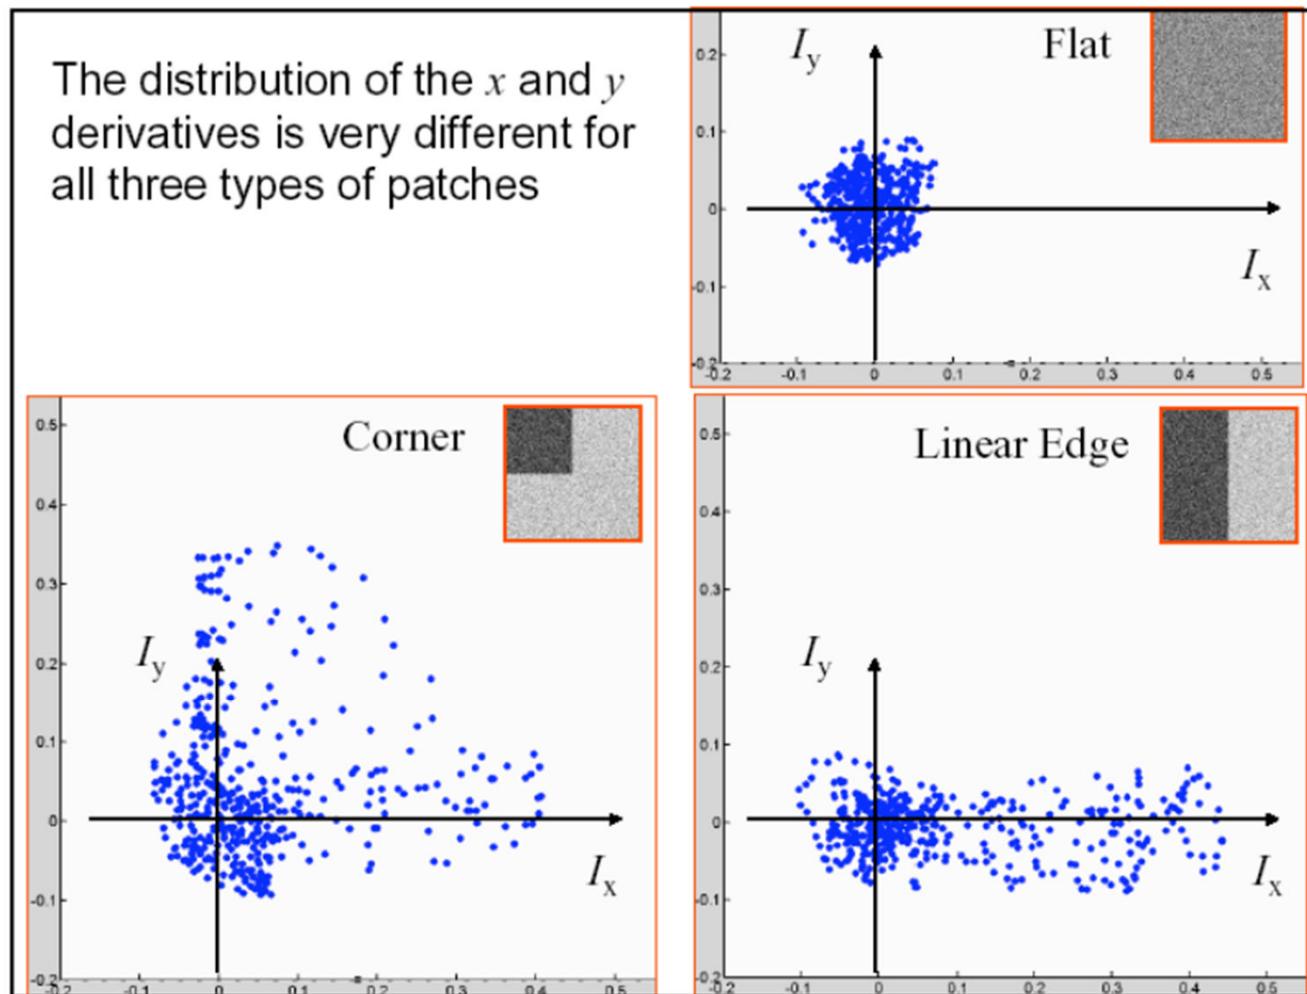


$I_X$



$I_J$

The distribution of the  $x$  and  $y$  derivatives is very different for all three types of patches



in A steckt Information bzgl. der  
Streuweite (analog zu PCA)



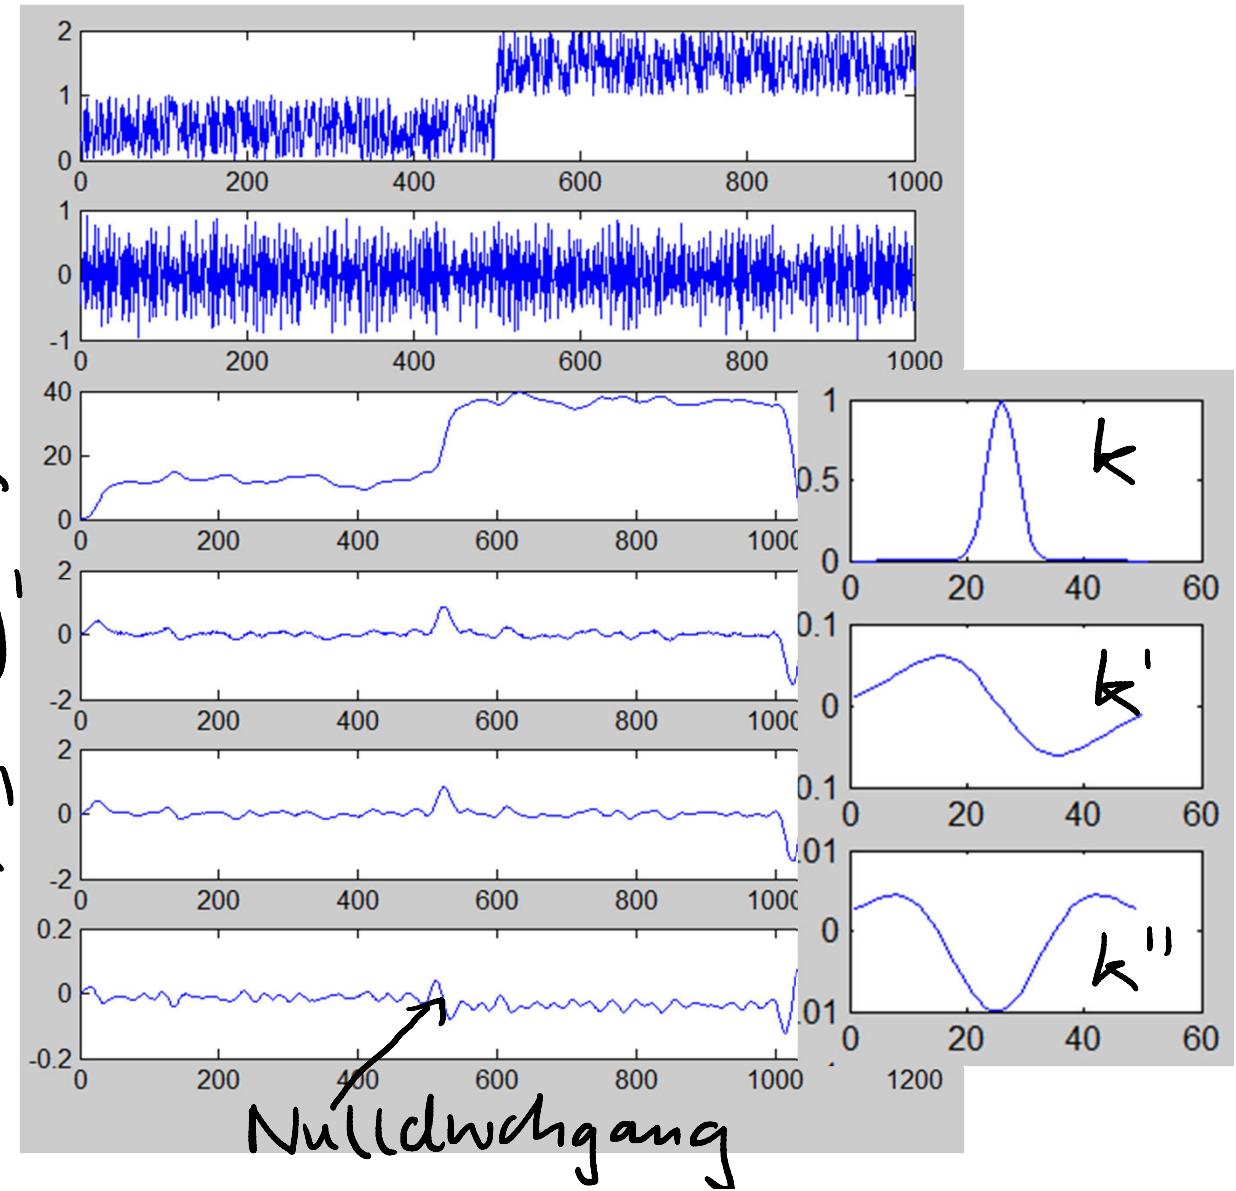
$\lambda_i$ : Eigenwerte von A

# Verbesser- und Vereinfachungen

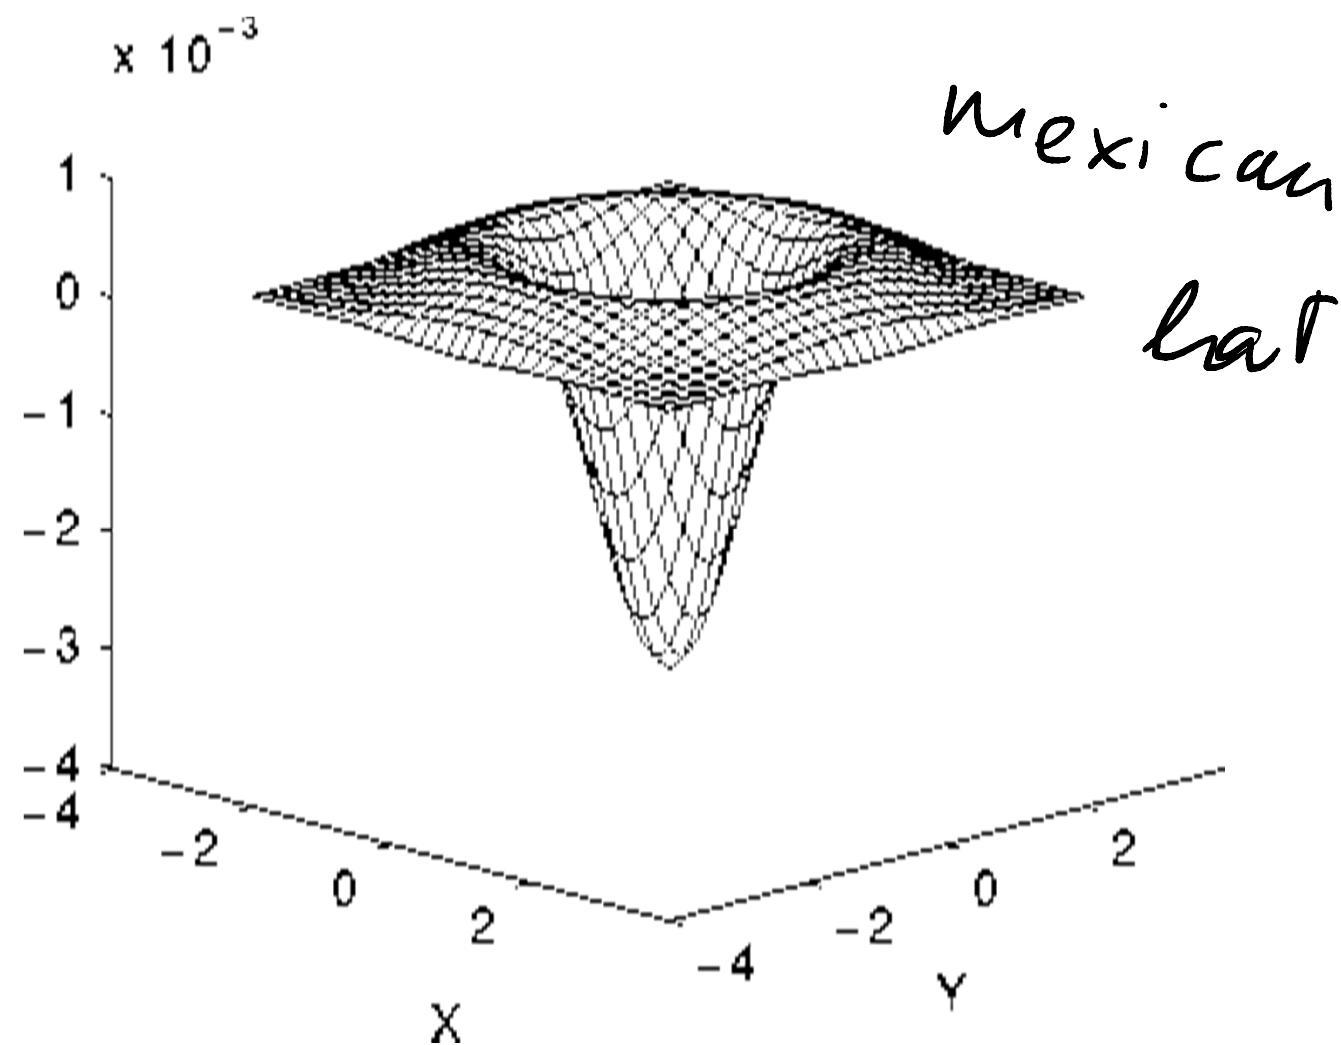
- w soll weich sein → gaussian window
- Eigenwerte berechnen ist teuer (Wurzel ziehen)
- Harris schlägt vor:  $R = \det(A) - k * \text{trace}(A)$   
mit  $k = 0.04$  bis  $0.06$

# Laplacian of Gaussian

Signal       $y$   
 $y'$   
 $y * k$   
 $(y * k)'$   
 $y * k'$   
 $y * k''$



# LoG und DoG



- LoG / DoG symmetrisch → man braucht nur einen Kernel zum Kantenfinden
- LoG / Dog symmetrisch → Konvolution ist Korrelation mit „rundem Objekt“ → LoG / DoG oft für Interest Point Detection verwendet
- LoG / DoG symmetrisch → rotationsinvariant