

VL 9: Lucas-Kanade

Optical Flow Tracking

Tracking

- Objektverfolgung, zwischen konsekutiven Frames
- oft mit einer Schätzung der Objektposition (zumindest alte Position)
- Detektion vs. Tracking

Classification of Tracking Methods

- Target Representation
 - Centroid, Bounding box, Skeletons, Silhouettes
- Appearance Model
 - Template image, Histograms (color, gradients, ...), Filter banks
- Motion Model
 - Rigid, similarity, affine, perspective transform
- (Dis-)Similarity Measures
 - SSD, Correlation
- Search Strategy
 - Exhaustive, Gradient, Stochastic

Optical Flow

- Spezialfall des Trackings
- Punktfeatures werden getrackt
- „dense“ und „sparse“ optical flow




Optical Flow

- Sparse optical flow
 - in Verbindung mit interest points (Harris Corners, Shi-Tomasi, SIFT, SURF, etc...)




Optical Flow


- Ill posed! „Aperture Problem“!



Optical Flow

- Ill posed! Aperture Problem






„Lucas-Kanade“

- Lucas, Kanade (1981): “An iterative image registration technique with an application to stereo vision”
- Shi, Tomasi (1994): „Good features to track”
- Bouguet (2001): „Pyramidal implementation of the affine lucas kanade feature tracker description of the algorithm”
- Baker, Matthews (2004): “Lucas-Kanade 20 Years On: A Unifying Framework”



1D-Tracking

$G(x) = F(x+h)$
 h ist der Versatz



$$F'(x) \approx \frac{F(x+h) - F(x)}{h}$$

$$= \frac{G(x) - F(x)}{h},$$

$$h \approx \frac{G(x) - F(x)}{F'(x)}$$

Der Versatz ist proportional zur Änderung der Helligkeit - (abhängig vom Anstieg)

$$h \approx \sum_x \frac{G(x) - F(x)}{F'(x)} / \sum_x 1.$$

Stabiler:

h in einer kleinen Region mitteln

$$F'(x) \approx \frac{G(x) - F(x)}{h}.$$

Approximation der zweiten Ableitung

$$w(x) = \frac{1}{|G(x) - F(x)|}.$$

Zweite Ableitung als Gewichtung

(große Krümmung -> wenig Vertrauen in die Vorhersage von h)

Übrigens: das h im Nenner sparen wir uns, weil ...

$$h \approx \sum_x \frac{w(x)[G(x) - F(x)]}{F(x)} / \sum_x w(x).$$

Wir normieren unsere Schätzung über alle Gewichtungen

$$h_0 = 0,$$

$$h_{k+1} = h_k + \sum_x \frac{w(x)[G(x) - F(x + h_k)]}{F(x + h_k)} / \sum_x w(x).$$

h wird iterativ verbessert, bis 1) k(l)eine Änderung oder 2) keine Lust

$$h \approx \sum_x \frac{w(x)[G(x) - F(x)]}{F(x)} / \sum_x w(x).$$

Wir normieren unsere Schätzung über alle Gewichtungen

$$h_0 = 0,$$

$$h_{k+1} = h_k + \sum_x \frac{w(x)[G(x) - F(x + h_k)]}{F(x + h_k)} / \sum_x w(x).$$

h wird iterativ verbessert, bis 1) k(l)eine Änderung oder 2) keine Lust

Alternative Formulierung

$$F(x+h) \approx F(x) + hF'(x)$$

Taylor Approximation (first term only)

$$\begin{aligned} 0 &= \frac{\partial E}{\partial h} \\ &\approx \frac{\partial}{\partial h} \sum_x [F(x) + hF'(x) - G(x)]^2 \\ &\quad \sum_x 2F'(x)[F(x) + hF'(x) - G(x)] \end{aligned}$$

$$h \approx \frac{\sum_x F'(x)[G(x) - F(x)]}{\sum_x F'(x)^2}.$$

Nur nicht definiert, wenn im gesamten Fenster $F' = 0$ ist

Mit Gewichtung:

$$h_0 = 0,$$

$$h_{k+1} = h_k + \frac{\sum_x w(x) F(x + h_k) [G(x) - F(x + h_k)]}{\sum_x w(x) F(x + h_k)^2}$$

Generalisierung zu N-D

$$E = \sum_{x \in R} [F(x+h) - G(x)]^2$$

SSD

$$F(x+h) \approx F(x) + h \frac{\partial}{\partial x} F(x)$$

Taylor

Generalisierung zu N-D

$$E = \sum_{x \in R} [F(x + h) - G(x)]^2 \quad \text{SSD}$$

$$F(x + h) \approx F(x) + h \frac{\partial}{\partial x} F(x) \quad \text{Taylor}$$

Zeilenvektor

Gradientenoperator
(ergibt Spaltenvektor)

$$\frac{\partial}{\partial x} = \left[\frac{\partial}{\partial x_1} \frac{\partial}{\partial x_2} \dots \frac{\partial}{\partial x_n} \right]^T$$

$$\begin{aligned}
0 &= \frac{\partial}{\partial h} E \\
&\approx \frac{\partial}{\partial h} \sum_x \left[F(x) + h \frac{\partial F}{\partial x} - G(x) \right]^2 \\
&= \sum_x 2 \frac{\partial F}{\partial x} \left[F(x) + h \frac{\partial F}{\partial x} - G(x) \right]
\end{aligned}$$

$$h = \left[\sum_x \left(\frac{\partial F}{\partial x} \right)^T [G(x) - F(x)] \right] \left[\sum_x \left(\frac{\partial F}{\partial x} \right)^T \left(\frac{\partial F}{\partial x} \right) \right]^{-1}$$

Trick-17e

- Gewichtung, wie im 1-D Fall
- Glättung! (was passiert sonst?)
- Pyramiden! (siehe Bouguet)

Motion Models

